

河南科技大学

HENAN UNIVERSITY OF SCIENCE & TECHNOLOGY

毕 业 设 计（论 文）

题目 基于机器学习的花卉识别系统的设计与实现

姓 名	<u>李志涛</u>
学 院	<u>信息工程学院</u>
专 业	<u>物联网工程</u>
指导教师	<u>范庆辉</u>

2025年5月25日

学位论文写作声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品或成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

论文作者签名：李志涛

日期：2025年5月25日

学位论文使用授权说明

本人完全了解河南科技大学关于收集、保存、使用学位论文的规定，即：按照学校要求提交学位论文的印刷本和电子版本；学校有权保存学位论文的印刷本和电子版，并提供目录检索与阅览服务；学校可以采用影印、缩印、数字化或其它复制手段保存论文；在不以赢利为目的的前提下，学校可以将学位论文编入有关数据库，提供网上服务。（保密论文在解密后遵守此规定）

论文作者签名：李志涛

导师签名：范庆辉

日期：2025年5月25日

基于机器学习的花卉识别系统的设计与实现

摘 要

随着人工智能和计算机视觉技术的快速发展，基于机器学习图像识别技术在多个领域广泛应用，由于传统花卉识别依赖人工经验、效率低下，为解决这样的问题，设计一款花卉识别系统是非常有必要的。

本文设计并实现了注意力机制驱动下的花卉识别系统，系统采用模块化的思想，主要包括数据预处理模块、模型训练与推理模块以及图形界面模块，数据预处理模块多种图像增强方法扩充数据集来提高模型的泛化能力；模型训练模块使用迁移学习技术，基于Pytorch框架构建SE+ResNet网络结构；图形界面模块利用Tkinter库进行开发，实现了图像上传和预测结果显示的交互功能，提高了系统的可用性和用户体验；通过测定准确率、召回率和F1值这三个评价指标，验证了本系统的准确性和有效性。

本论文实现了花卉图像高效识别，具备良好的扩展性与实用性，能为农业、园艺等领域提供便捷智能识别服务，也可以作为普通用户识别各种花卉提供方便。

关键词：机器学习；花卉识别；注意力机制；图像分类；迁移学习

DESIGN AND IMPLEMENTATION OF FLOWER RECOGNITION SYSTEM BASED ON MACHINE LEARNING

ABSTRACT

With the rapid development of artificial intelligence and computer vision technology, image recognition technology based on machine learning is widely used in many fields, because the traditional flower recognition relies on manual experience and low efficiency, in order to solve such a problem, it is very necessary to design a flower recognition system.

In this paper, a flower recognition system driven by attention mechanism is designed and implemented, which adopts the idea of modularization, mainly including data preprocessing module, model training and inference module, and graphical interface module, and a variety of image enhancement methods in the data preprocessing module to enrich the dataset to improve the generalization ability of the model. The model training module uses transfer learning technology to construct the SE ResNet network structure based on the Pytorch framework. The graphical interface module is developed using the Tkinter library, which realizes the interactive functions of image upload and prediction result display, and improves the usability and user experience of the system. The accuracy and effectiveness of the system were verified by measuring the accuracy, recall and F1 value.

This paper realizes the efficient recognition of flower images, which has good scalability and practicability, and can provide convenient intelligent recognition services for agriculture, horticulture and other fields. At the same time, it can also be used as an ordinary user to identify various flowers to provide convenience.

KEY WORDS: Machine Learning; Flower Recognition; Attention Mechanisms; Image Classification; Transfer Learning

目 录

第1章 绪 论	1
§1.1 研究背景及意义	1
§1.2 国内外研究现状	1
§1.3 本文主要研究内容	2
第2章 算法分析	3
§2.1 ResNet基线网络结构	3
§2.2 ResNet的局限性分析与改进动机	3
§2.3 SE模块的注意力机制原理	4
第3章 总体设计	6
§3.1 环境构建与配置	6
§3.2 系统模块划分	6
§3.2.1 数据预处理	6
§3.2.2 模型训练	7
§3.2.3 UI界面设计	7
§3.3 系统总体流程	7
第4章 详细设计	8
§4.1 数据预处理实现	8
§4.1.1 数据增强策略	8
§4.1.2 数据集划分	8
§4.2 模型训练与调优	9
§4.2.1 SE-ResNet网络实现	9
§4.2.2 损失函数选择	10
§4.2.3 优化器与学习率策略	11
§4.2.4 模型训练策略	13
§4.3 系统功能模块实现	13
§4.3.1 模型训练模块	14
§4.3.2 图像上传模块	14
§4.3.3 结果可视化界面	14

§4.4 本章小结-----	15
第5章 系统测试 -----	17
§5.1 评价指标-----	17
§5.2 模型性能测试-----	17
§5.2.1 SE-ResNet与基线模型对比实验-----	17
§5.2.2 不同超参数对性能的影响 -----	18
§5.3 系统功能测试-----	18
总结与展望 -----	19
参考文献 -----	20
致 谢 -----	22

第1章 绪 论

§1.1 研究背景及意义

随着人工智能的进步，计算机视觉技术已经广泛应用到很多的领域，比如在医学影像的组织病理切片诊断^[1]、肺部肿瘤检测^[2]、眼底病变识别^[3]，在现代农业中的农作物品种分类^[7]、病虫害识别^[8]、农产品质量评估^[9]，在交通系统的机动车辆识别^[4]、车牌识别^[5]、交通标识检测^[6]等领域图像分类都发挥着重要的作用，但是在一些细粒度图像识别任务中的分类效果却显得没有那么好，比如在花卉这种特殊的植物上，不同种类之间特征相似而同一种类之间差异显著，而且现在花卉种类识别技术对金丝贯顶这种形态独特、特征复杂的花并不起效，往往会识别成其他的花卉，现有的训练方法很容易忽略这类图像的底层特征，然而这些被忽略的特征恰恰是识别不同品种花卉的关键，所以花卉识别的核心问题是怎么充分提取图像特征，提高识别的准确率。

本文针对现有花卉识别技术的不足和一些特殊的花卉如金丝贯顶，研究提取图像特征能力更强大的模型，改进提取特征的方法，能够更精细地捕捉花卉的底层特征。

§1.2 国内外研究现状

当前人工智能领域出现了许多新型模型，卷积神经网络（CNN）因其独特的参数共享机制、稀疏连接特性以及降采样策略在机器学习中成为了很多研究者的首要选择，CNN自从LeNet-5^[11]首次被提出后架构持续创新，在2012年ImageNet竞赛^[12]中AlexNet^[10]以显著优势领先，ILSVRC 2014赛事中VGGNet^[14]与GoogleNet^[15]凭借创新设计展露头角，2015年采用残差学习框架的ResNe^[16]在同类竞赛中表现突出，CNN在计算机视觉识别任务中的表现不断突破，若是应用到花卉识别领域则可以有效提升分类准确率并且为相关产业发展提供有力技术支撑。

目前国内外已经有许多研究者在花卉识别领域利用CNN获得创新性成果，王爽^[17]利用支持向量机分类策略并通过调整已经在ImageNet上预训练的AlexNet参数，在Oxford-102 flowers花卉数据集中获得了90.25%的分类准确率，尹红^[18]设计出了一种不需要监督的大规模花卉识别方案，该方案对图像进行标准化处理，运

用迁移学习技术使用VGG-16模型，并且把视觉上的显著特征与深度卷积特征相结合，最后采用Softmax分类器完成分类任务，MUsa团队^[19]创新型地将AlexNet和VGG16提取的特征向量进行融合，通过特征选择算法来筛选出最具判别性的特征子集，在支持向量机分类器的作用下在Oxford-102 flowers数据集上实现了高达95.70%的准确率，吴迪^[20]等人采用Tanh-ReLu复合激活函数代替传统ReLu对InceptionV3网络进行改进，微调参数后准确率到达了92.85%，牛源^[21]的研究侧重于网络结构优化，通过在VGG-16中集成特征金字塔融合模块与残差注意力机制，配合PCA-局部敏感哈希索引算法，显著提高了检索效率和准确率。

机器学习中基于卷积运算的神经网络模型由于优秀的特征学习能力和对复杂关系的建模能力成为了计算机视觉领域的主流技术方案，虽然这种网络架构消耗资源较大、模型训练周期长、泛化能力不足，但是可以通过优化算法和升级硬件来提升性能。

§1.3 本文主要研究内容

由于同类花卉之间差异显著、不同种类之间形态相似等问题，本文提出了基于SE-ResNet架构的花卉识别系统，以ResNet为主干网络，为了提高细微特征的提取效果和减少训练时间，本文决定使用迁移学习技术加载ImageNet上的预训练参数，在训练过程中固定网络前端层的权重仅调整最后三个全连接层的参数来满足特定分类需求，本文也采用了多种图像变换技术扩展数据集来解决训练样本不足的问题，在验证环节使用了Oxford-102 flower官方数据集和自主采集的牡丹图像数据集进行测试，然后通过消融实验证明了SE模块可以明显提升分类的准确率。

第2章 算法分析

§2.1 ResNet基线网络结构

为了构建一个识别效率高且准确率高的花卉图像分类模型，本文选择ResNet作为基础网络结构，ResNet是一种深度残差网络，其核心结构在于它引入了残差模块，有效地缓解了训练过程中梯度消失和网络退化等问题，能够让模型稳定训练且可以使网络深度扩展到上百层。

§2.2 ResNet的局限性分析与改进动机

ResNet的核心结构是残差模块：

$$y = \mathcal{F}(x, w_i) + x \quad (2.1)$$

其中， x 是输入特征， y 是输出特征， $\mathcal{F}(x, w_i)$ 是残差函数，由多个卷积层组成，尽管ResNet在图像分类任务中表现优异但是仍然存在一些问题，它的卷积操作侧重空间维度（如 3×3 ）而对通道间依赖性建模能力较弱，在训练过程中所有通道的权重都一样而且固定，无法根据输入的图片动态调整通道权重，同时它仅仅通过简单加法跨层连接融合特征（图 2-1），没有明确各通道的权重，在花卉识别分类任务中，部分通道可能含有花瓣纹理信息而其他通道可能捕获背景噪音，ResNet却无法自动区分并处理这种差异，ResNet在光照变化、遮挡、视角变化等复杂环境下不能智能化地进行特征提取，这可能会影响模型在不同条件下的表现与稳定性，比如在强光或者阴影下、花卉部分被遮挡或不同角度拍摄时无法有效识别并提取关键特征，这将直接导致模型准确性与可靠性下降。

residual结构




图 2-1 ResNet特征融合原理

所以本文引入Hu等人^[24]在2018年提出的Squeeze-and-Excitation (SE) 模块解决上述问题, 这个模块对卷积特征图的各个通道进行建模, 自动学习每个通道的权重, 依此对特征图加权调整, 让模型能够更好地提取关键特征, 有效弥补了ResNet在通道注意力方面的不足, 在花卉识别这种细粒度分类任务中能显著提升模型判别能力与整体性能。

§2.3 SE模块的注意力机制原理

图 2-2展示的SE (Squeeze-and-Excitation) 模块采用了自适应通道加权机制, 它的工作原理分三个关键步骤, 其一是通过全局池化操作压缩空间维度信息 (Squeeze阶段), 其二是利用全连接层学习通道间依赖关系 (Excitation阶段), 其三是将学习到的权重与原始特征图相乘完成特征重标定 (Re-weighting), 这样的设计可以让网络能够自主强化判别性特征弱化冗余信息。

在特征处理过程中Squeeze阶段利用全局平均池化技术将 $H \times W$ 尺寸的二维特征映射转为单个数值输出来实现空间维度信息浓缩, 并产生通道描述向量来表征各通道全局特征分布, 输入特征张量中高度 H 与宽度 W 代表空间尺度、通道数 C 表示特征维度, 沿空间轴执行均值计算把每个通道的二维特征矩阵压缩成标量值进而形成含 C 个元素的特征向量以完整保留各通道的全局统计特性, 这一过程可形式化表示为:

$$Z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u_c(i, j) \quad (2.2)$$

其中, Z_c 代表第 C 个通道的全局平均值。




图 2-2 SENet结构图

Excitation阶段依据前面获取的通道全局特征动态生成各通道加权系数突出关键特征通道弱化次要通道, 采用两层全连接结构并在结构之间引入ReLU非线性变换及维度变换操作来有效地降低模型复杂度, 具体实现时需要给定初始通道数 C 与

压缩比例 r ，第一层全连接把特征维度从 C 压缩至 C/r ，经ReLU激活后第二层全连接将维度恢复至原始通道数 C ，最终通过Sigmoid函数把输出值约束在0到1区间形成通道注意力权重向量 $\mathcal{S}$ 。即

$$\mathcal{S} = \sigma(\mathcal{W}_2 \delta(\mathcal{W}_1 \mathcal{Z})) \quad (2.3)$$

其中， δ 代表ReLU激活函数， σ 代表Sigmoid函数，这种设计能够保持特征表达能力并显著减少参数规模。

Re-weighting用学习到的通道权重 $\mathcal{S}$ 作用到原始特征图 $\mathcal{U}$ 上实现通道级特征调制，通过自适应加权机制增强判别性强的特征通道且减弱次要特征通道的影响，这个过程可形式化地描述为将维度为 $C \times H \times W$ 的输入特征图与 C 维通道权重向量逐通道乘积运算最终输出优化后的特征表示，这种操作能有效提升网络对关键特征的敏感性，数学表达式如下：

$$\tilde{\mathcal{U}}_c = \mathcal{S}_c \cdot \mathcal{U}_c \quad (2.4)$$

这里的 $\tilde{\mathcal{U}}_c$ 就是经过SE模块处理后的特征图，它更加强调了那些对任务更有帮助的特征。

SE模块有效地解决了卷积神经网络中通道特征自适应优化的问题，通过动态学习通道间相关性来实现特征通道智能筛选与强化，在花卉图像分类任务中这种设计能够自主识别并突出最具判别力的特征而且弱化了干扰信息，实验证明这种特征选择策略显著提升细粒度分类任务的模型性能表现，增强模型对关键细节的捕捉能力。

第3章 总体设计

§3.1 环境构建与配置

考虑到深度学习模型训练过程中对计算机资源的高要求，本系统是在一台具备中等算力的个人计算机上进行开发和测试的，具体硬件配置见表 3-1，在软件方面，本系统基于Python编程语言开发，采用Pytorch深度学习框架来构建和训练模型，软件环境配置信息见表 3-2。

表 3-1 硬件配置信息表

组件	配置信息
处理器（CPU）	Intel(R) Core(TM) i5-11400H @ 2.70GHz
显卡（GPU）	NVIDIA GeForce RTX3050
内存	16GB DDR4
外存	512GB NVMe SSD
操作系统	Windows 11 家庭版

表 3-2 软件环境配置表

软件库/包	版本号
Python	3.8.20
Pytorch	1.11.0+cu113
cv2	4.10.0
pillow	10.4.0
NumPy	1.24.4
Scikit-learn	1.3.2

§3.2 系统模块划分

§3.2.1 数据预处理

初始获取的大部分花卉图像包含噪声污染、光照分布不均以及复杂背景等多种干扰因素，这样会显著影响模型训练的效果，然而图像预处理技术能够通过噪

声消除、色彩空间转换、亮度调整等操作可以有效地改善数据质量，经过处理步骤后图像的关键特征信息得到了增强而无关干扰信息被有效地抑制，为后续模型训练提供了更高质量的输入数据。

§3.2.2 模型训练

核心训练模块使用了深度学习方法，让神经网络模型根据带标签的数据不断优化自身，最终变成高精度分类模型，系统选择SE-ResNet混合架构作为基础分类器，在初始阶段会加载ImageNet预训练参数提升训练效率，用AdamW优化算法进行参数更新配合余弦退火学习率调节策略动态控制收敛过程，还选择交叉熵作为模型优化目标函数，为系统提供了可靠的分类能力。

§3.2.3 UI界面设计

为了提升用户体验，本文使用Python的Tkinter库设计了一个直观且方便操作的UI界面，该界面支持用户上传花卉图片，自主选择用来预测的模型，实时展示并保存系统的识别结果。

§3.3 系统总体流程

用户可以在界面里自主选择用来预测的模型，打开文件夹选择想要识别的花卉图片，被选中的图片会通过数据预处理模块进行降噪，再由SE-ResNet模型对处理后的图片进行深层次的特征提取分析并预测图片中花卉的种类，最后在UI界面中展示预测结果并保存到指定路径。

第4章 详细设计

§4.1 数据预处理实现

§4.1.1 数据增强策略

为了提升模型的泛化能力和鲁棒性，本文在数据预处理阶段对训练集采用了多种图像随机增强策略，主要包括将所有输入图像统一缩放至固定大小（如 224×224 ）、随机旋转（最大角度 45° ）、随机水平/垂直翻转和随机灰度转换，如图 4-1 是原始数据图片，图 4-2 是经过图像随机增强策略之后的数据图片。




图 4-1 原始图片




图 4-2 处理后的图片

§4.1.2 数据集划分

本文使用的花卉数据集是公开数据集 Oxford 102 Flowers Dataset 以及自建

的花卉图像数据，一共包括 112 种常见花卉，数据总量超过 10000 张，所有图像被划分为三个文件夹（如图 4-3所示），其中带有标签的数据按照 7:3 的比例分别划分到训练集和验证集中，无标签数据划分到测试集里面。

test	2025/4/4 22:41	文件夹
train	2025/4/5 21:21	文件夹
val	2025/4/5 21:32	文件夹

图 4-3 数据集划分后的文件夹

§4.2 模型训练与调优

§4.2.1 SE-ResNet网络实现

本文采用的方法是将SE模块融合到经典的ResNet网络结构中来增强模型对关键特征的提取能力，具体来说设计了两种改进型残差结构—SEBasicBlock和SEBottleneck，分别适配于ResNet-18/34与ResNet-50/101/152系列模型，这两种模块在原有残差块的基础上引入了SE机制，从而在网络内部实现了通道注意力机制的有效建模，在SE残差结构中，输入数据经过标准卷积层与批量归一化处理，随后通过激活函数引入非线性特性，数据进入第二层卷积与归一化操作后，被送入SE模块进行通道注意力权重的计算，最后依据是否需要进行下采样操作，将SE模块输出与原始输入进行相加融合并再次激活，完成一次完整的前向传播过程，以SEBasicBlock为例，将SE模块引入后，输出变为：

$$\mathcal{Y} = \mathcal{S} \odot \mathcal{F}(\mathcal{X}) + \mathcal{X} \quad (4.1)$$

其中，输入为 $\mathcal{X} \in \mathcal{R}^{\mathcal{H} \times \mathcal{W} \times \mathcal{C}}$ ， $\mathcal{S} \in \mathcal{R}^{\mathcal{C}}$ 是通过SE模块计算得到的通道注意力权重向量， $\odot$ 表示逐元素乘法操作，对于SEBottleneck，由于其包含三个卷积层（1x1,3x3,1x1），因此在第三个卷积层之后插入SE模块，公式保持一致，但 $\mathcal{F}(\mathcal{X})$ 现在包含了更复杂的变换过程，为进一步强化SE模块的作用，本文在ResNet的最后一层全连接层前构建了一个复合结构，包含多个SE残差块，并结合Dropout机制，以提升模型泛化能力并抑制过拟合，设输入特征维度为 $\mathcal{D}$ ，通过线性变换 $\mathcal{W} \in \mathcal{R}^{\mathcal{D} \times \mathcal{D}'}$ 映射到新的特征空间，其中 $\mathcal{D}'$ 为目标维度，则有 $\mathcal{X}' = \sigma(\mathcal{W}^T \mathcal{X})$ ，接着应用SE模块调整通道注意力，最终输出为 $\mathcal{Y}' = \mathcal{S}' \odot \mathcal{X}'$ ，其中 $\mathcal{S}'$ 是SE模块基于 $\mathcal{X}'$ 计算得出的通道注意力权重。

基于上述设计，本文构建了多种深度的SE-ResNet模型，包括

SE-ResNet18/34/50/101/152，这些模型均基于PyTorch提供的ResNet预训练模型架构，把原有残差块替换为SE块，并重新配置最后的全连接层来实现模型构建。

§4.2.2 损失函数选择

在深度学习图像分类任务中，损失函数的选择对模型的训练效果和最终性能具有重要影响。

表 4-1 不同损失函数的优缺点

损失函数类型	优点	缺点
Cross-Entropy Loss	实现简单、梯度稳定、广泛使用	对类别不平衡
Focal Loss	缓解类别不平衡问题	参数敏感、可能影响收敛速度
Label Smoothing	提升泛化能力、缓解过拟合	训练初期收敛稍慢

表 4-1是各类损失函数对比分析的相关信息，为了更直观地展示不同损失函数在花卉识别任务中的表现，本文在相同的SE+ResNet34模型架构上分别使用三种不同的损失函数进行训练，所有模型均在同一花卉图像数据集上训练，并使用相同的超参数设置，以便公平比较，将从准确率（Accuracy）、召回率（Recall）、F1值三个方面评估各模型的性能。




图 4-4 对比三个损失函数的准确率




图 4-5 对比三个损失函数的F1值




图 4-6 对比三个损失函数的召回率

对比实验结果如图 4-4、图 4-5、图 4-6所示，在使用FocalLoss作为损失函数时，模型的整体性能相比其他两种损失函数有所下降，而LabelSmoothing虽然作为交叉熵损失的一种改进形式，在一定程度上能提升模型性能，但在训练过程中的表现不够稳定，相比之下，标准的交叉熵损失函数表现出更好的稳定性与收敛性，并且两者的准确率只相差不到1.5%，因此，本文最终选择交叉熵损失函数作为模型训练的主要优化目标。

§4.2.3 优化器与学习率策略

AdamW是对经典Adam优化器的一种改进版本，其核心改进在于将权重衰减从梯度更新中分离出来，使其真正意义上实现L2正则化的效果，从而提高模型的泛化能力，由表 4-2可知，AdamW相较于传统SGD和原始Adam具有更强的泛化能力、更稳定的训练过程等优势，更适合大规模数据训练，表 4-3是AdamW的超参数设置信息。

表 4-2 三个优化器的对比

优化器	优点	缺点
SGD	1. 对小数据集表现稳定 2. 配合学习率调度器效果更好 3. 简单易懂，理论分析清晰	1. 学习率需要手动调整，对初始值敏感 2. 收敛速度较慢，需要更多迭代次数 3. 对特征尺度敏感
Adam	1. 通常收敛速度快，适合大规模数据和深度学习 2. 自动调整不同参数的学习率	1. 可能在某些情况下无法收敛到最优解 2. 对权重衰减（L2正则化）的实现可能不理想
AdamW	1. 在训练深度学习模型时表现更稳定 2. 保留Adam自适应学习率的优点 3. 适合需要显式权重衰减的任务，如预训练模型	1. 超参数仍需调优 2. 计算开销略高于Adam但差异不大 3. 对小数据集可能不如SGD表现好

表 4-3 AdamW优化器超参数的数值

参数名称	数值
学习率	0.001
权重衰减系数	0.00001

CosineAnnealingLR是一种基于余弦退火机制的学习率调度策略，可以模拟周期性地降低学习率的过程，帮助模型更好地跳出局部最优解，获得更优的全局最小值，学习率随训练轮次变化的计算公式如下：

$$\eta_t = \eta_{min} + \frac{1}{2}(\eta_{max} - \eta_{min}) \left(1 + \cos \left(\frac{T_{cur}}{T_{max}} \pi \right) \right) \quad (4.2)$$

表 4-4 变量名的含义

η_t	当前学习率
η_{min}	最小学习率
η_{max}	最大学习率
T_{cur}	当前训练轮次数
T_{max}	一个完整余弦周期的总轮次数

表 4-4是变量名所代表的含义，CosineAnnealingLR的超参数设置见表 4-5

表 4-5 CosineAnnealingLR超参数设置

参数名称	数值
最大学习率	0.001
最小学习率	0.00001
周期长度（T_max）	10

本文采用AdamW优化器结合CosineAnnealing学习率调度器来进行网络参数的更新和学习率的调整，通过使用AdamW优化器，可以在保持Adam优化器自适应学习率优点的同时，更有效地进行权重衰减处理，有助于提升模型的泛化能力，CosineAnnealing学习率调度器能够根据训练进程平滑地降低学习率，模仿了余弦函数的下降趋势，这有助于模型在训练的后期更加精细地调整参数，从而促进模型收敛并可能找到更优的局部最小值，这样的组合为SE-ResNet模型在花卉图像识别任务中的表现提供了有力的支持

§4.2.4 模型训练策略

在实验中，冻结了除最后一层外的所有网络参数，允许最后三层的参数更新来加速训练并减少过拟合风险，采用AdamW优化器进行参数更新，学习率调度采用了余弦退火策略（CosineAnnealingLR），10个epoch为周期动态调整学习率，还使用了交叉熵损失函数（CrossEntropyLoss）作为训练过程中的目标函数，衡量预测结果与真实标签之间的差异，每个训练epoch中，计算训练集上的平均损失loss和准确率accuracy，并记录至列表中用于后续可视化，在每个epoch结束后，切换至评估模式，在验证集上进行性能评估，同样记录验证损失和准确率，若当前验证准确率高于历史最大值，则保存当前模型状态至指定路径。

§4.3 系统功能模块实现

§4.3.1 模型训练模块

模型训练模块负责完成深度学习模型的初始化、参数优化与性能评估，该模块基于PyTorch框架实现，通过加载预训练权重提升模型的收敛速度和分类性能，在训练过程中使用AdamW优化器进行参数更新，并结合CosineAnnealingLR学习率调度策略动态调整学习率，以提升模型稳定性和泛化能力，损失函数选用交叉熵损失函数监督分类任务，同时该模块支持冻结部分网络层，训练过程中实时记录训练损失和验证准确率，并在验证准确率达到最优时保存模型权重。

§4.3.2 图像上传模块

图像上传模块是用户与系统交互的第一步，主要用于从本地设备中选择待识别的花卉图像，该模块基于Tkinter库构建图形界面，通过filedialog组件实现文件夹路径的选择功能，用户可导入包含花卉图片的目录，系统自动筛选出.jpg、.png等图像格式并展示在列表框中如图 4-7，选中一张图像后，系统将获取其完整路径并缓存，供后续推理过程使用，为增强程序安全性，该模块还引入了临时文件管理机制，防止原始图像被意外修改或覆盖，同时也具备错误处理功能，当未找到有效图像或路径为空时会弹出提示信息，提升系统的容错能力和用户体验。




图 4-7 点击选择文件夹后的效果

§4.3.3 结果可视化界面

结果可视化界面用于直观展示图像识别结果，提升系统的可操作性与交互性，

该界面基于Tkinter库开发，包含图像显示区域、模型选择按钮、预测结果显示区域和结果保存四大组成部分，用户自主选择用来预测的模型，选择指定的图片文件后点击“显示图片”按钮，所选图像将在指定区域内以统一尺寸如256×256像素展示，点击“预测”按钮后，系统调用训练好的SE+ResNet模型对图像进行前向传播计算，并将识别结果以文本形式展示在界面上如图 4-8，也可以将结果保存到指定文件夹，适合非专业用户快速获取花卉识别信息。




图 4-8 预测结果可视化

§4.4 本章小结

本章围绕系统的详细设计与实现展开，介绍了开发环境的配置情况，包括操作系统、硬件平台及所使用的软件工具，确保系统在高效稳定的环境下运行；接着描述了数据预处理的具体实现方法，包括图像缩放、随机旋转、水平翻转、灰度转换等增强策略，并通过ToTensor()转换和基于ImageNet的归一化操作提升模型收敛速度，在验证和测试阶段仅保留必要处理步骤，以保证预测结果的一致性和稳定；在模型训练部分，详细阐述了SE-ResNet网络结构的设计原理，通过将SE模块嵌入ResNet残差块，增强了模型对关键通道特征的关注能力，并结合迁移学习加载预训练权重，冻结浅层参数，仅微调最后三层，以提高训练效率并减少过拟合风险；对损失函数进行了对比实验，分别使用交叉熵损失、Focal Loss和Label Smoothing进行性能评估，最终选择交叉熵损失作为目标函数，因其在准确率和稳

定性方面表现更优；优化器方面采用AdamW结合CosineAnnealingLR学习率调度策略，动态调整学习率，提升模型收敛性与泛化能力；还介绍了系统功能模块的具体实现，包括模型训练模块、图像上传模块和结果可视化界面，各模块协同工作，实现了从数据输入、模型推理到结果展示的完整流程，提升了系统的可用性与交互体验，通过上述设计与实现，本章为后续模型训练与系统测试打下了坚实的基础。

第5章 系统测试

§5.1 评价指标

在评估花卉识别系统性能时，本文采用了准确率（Accuracy）、召回率（Recall）和F1值作为主要评价指标，这些指标能够全面反映模型在不同类别上的分类效果，其中准确率衡量了所有预测为正类的样本中有多少是真正正确的，召回率则表示实际为正类的样本中有多少被正确识别出来，而F1值则是准确率与召回率的调和平均数，提供了对分类器性能的一个综合考量，在不平衡数据集上非常有用，如图 5-1，在训练和验证环节，均记录了这些评价指标的数值而且绘制了变化曲线，可以发现在验证环节中模型的表现非常好，符合最初的预期。




图 5-1 各个评价指标在训练中的变化曲线

§5.2 模型性能测试

§5.2.1 SE-ResNet与基线模型对比实验

为了验证SE-ResNet改进模型的有效性，本文将其与原始ResNet模型进行了对比实验，结果显示如图 5-2，在相同训练条件下，SE-ResNet模型在测试集上的准确率、召回率和F1值均优于基线模型，具体而言，SE-ResNet模型的准确率提升了约3%，召回率提高了约4%，F1值也相应增加了，这表明通过引入SE模块增强通道间特征的重要性权重调整，确实有助于提升模型的表现特别是在细粒度分类任务中。




图 5-2 有SE和无SE的ResNet模型性能对比

§5.2.2 不同超参数对性能的影响

本文也研究了不同超参数设置对模型性能的影响，包括批量大小、初始学习率以及权重衰减系数等关键参数，实验发现，适当增加批量大小有助于提高模型稳定性但可能延长收敛时间；初始学习率过高会导致训练初期损失波动剧烈，过低则会拖慢收敛速度，经多次尝试，确定0.001为较优初始学习率；权重衰减系数设为0.0001时，在防止过拟合的同时保持了较高的模型精度，合理选择超参数对于优化模型性能至关重要。

§5.3 系统功能测试

除了模型层面的性能测试外，本文也对系统的整体功能进行了全面检验，主要包括图像上传模块、模型推理模块以及结果可视化界面的功能完整性与稳定性测试，图像上传模块支持用户便捷地从本地导入花卉图片，并能自动筛选出有效的图像格式进行展示，模型推理模块能够在接收到图像后快速调用预训练好的模型进行预测，输出精确的分类结果；结果可视化界面设计直观友好，用户可以轻松查看预测结果，总体来看，本系统各功能模块协同工作良好，满足了预期的设计要求。

总结与展望

本文针对花卉图像识别领域构建了一个基于机器学习的花卉识别系统，核心是改进的SE-ResNet架构，主要由数据预处理、模型训练和预测、UI界面三大功能模块组成，主要研究成果如下：

理论方面，本文研究深度卷积网络的工作原理，探讨了残差网络与注意力机制的结合方式，为改进模型打好了理论基础，系统设计用分层架构，划分为数据预处理、模型训练、图像输入与结果展示等功能单元，模块间通信通过标准接口来实现，这样保证了系统的可扩展性；在实验环节为了让模型具有可信力，用多维度评估模型性能，包含准确率、召回率、F1值等关键指标，测试数据显示融合了SE模块的ResNet模型提升了分类精度，在复杂光照和不同拍摄环境条件下展现了优异的稳定性，然后进行了对比实验和参数优化，证明了模型改进方案的有效性；为了让用户方便获取花卉识别服务，还使用了Python的标准GUI库Tkinter设计了一个直观且易于操作的UI界面，集成图像上传、结果展示等核心功能。

当前系统虽然初步取得了较好的识别效果，但是仍然有几个值得深入探索的方向，假如现在要维持精度的同时要提升训练效率，那么可以考虑集成更高效的注意力机制如CBAM或者采用轻量级的网络架构如EfficientNet；现有的训练样本在数量和多样性上也有局限，后续可以通过网络爬取等方法扩充规模，引入持续学习机制来提升模型泛化能力；当前系统只支持单张静态图像识别，未来可以增加批量处理、实时视频分析、拍照识别等功能，让系统更贴合实际使用场景。

参考文献

- [1] 王娟.基于深度学习的癌变组织切片图像识别技术研究[D].上海第二工业大学,2024.DOI:10.27916/d.cnki.ghdeg.2024.000148.
- [2] 吴凯佳.基于迁移学习的肺癌病理图像分类研究[D].南昌大学,2024.DOI:10.27232/d.cnki.gnchu.2024.004674.
- [3] 何夏兰.基于深度学习的视网膜眼底图像分割与病变分类研究[D].南京林业大学,2024.DOI:10.27242/d.cnki.gnjlu.2024.000176.
- [4] 牟俊宇,陈菲,韩钰松,等.基于注意力机制改进YOLOv7算法的车辆识别检测[J].齐鲁工业大学学报,2025,39(02):8-16.DOI:10.16442/j.cnki.qlgydxxb.2025.02.002.
- [5] 刘凌远.基于深度学习的车牌检测与识别[J].现代信息技术,2024,8(23):53-57.DOI:10.19850/j.cnki.2096-4706.2024.23.012.
- [6] 李志明,梁莹莹,吴豆豆,等.基于卷积神经网络的交通标志识别系统设计与实现[J].电脑知识与技术,2025,21(04):32-35+41.DOI:10.14004/j.cnki.ckt.2025.0169.
- [7] 阳灵燕,张红燕,陈玉峰,等.机器学习在农作物品种识别中的应用研究进展[J].中国农学通报,2020,36(30):158-164.
- [8] 蔡国庆,吴建军,祝玉华,等.基于卷积神经网络的农作物病虫害检测研究进展[J].山东农业科学,2024,56(11):170-180.DOI:10.14083/j.issn.1001-4942.2024.11.023.
- [9] 方孝荣.基于深度学习BP人工神经网络的农产品质量检测[J].金华职业技术学院学报,2016,16(03):73-76.
- [10] Krizhevsky A, Sutskever I, Hinton G E. ImageNet Classification with Deep Convolutional Neural Networks[J]. Neural Information Processing Systems, 2012, 1:1097-1105.
- [11] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [12] Deng J, Dong W, Socher R, et al. Imagenet: A large-scale hierarchical image database[C]//2009 IEEE conference on computer vision and pattern recognition. Ieee, 2009: 248-255.
- [13] Russakovsky O, Deng J, Su H, et al. Imagenet large scale visual recognition challenge[J]. International journal of computer vision, 2015, 115(3): 211-252.
- [14] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [15] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings

- of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.
- [16]He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [17]王爽.基于机器学习的花卉识别算法的研究与实现[D].电子科技大学,2018.
- [18]尹红.基于深度学习的花卉图像分类算法研究[D].南昌航空大学,2018.
- [19]Cibuk M,Budak U,Guo Y,et al.Efficient deep features selections and classification for flower species recognition[J].Measurement,2019,137:7-13.
- [20]吴迪,侯凌燕,刘秀磊,等.一种改进的深度神经网络的花卉图像分类[J].河南大学学报(自然科学版),2019,49(02):192-203.DOI:10.15991/j.cnki.411100.2019.02.008.
- [21]牛源.基于深度学习的花卉图像检索系统的研究与实现[D].扬州大学,2019.DOI:10.27441/d.cnki.gyzdu.2019.001168.
- [22]秦敏.基于深度学习的花卉图像分类识别模型研究[D].广西师范大学,2020.DOI:10.27036/d.cnki.ggxsu.2020.000496.
- [23]裴晓芳,张杨.基于改进残差网络的花卉图像分类算法[J].电子器件,2020,43(03):698-704.
- [24]Hu, J., et al. (2018). Squeeze-and-Excitation Networks. TPAMI, 42(8), 2011-2023.
- [25]曾浩.基于深度学习的图像识别算法优化与应用研究[J].家电维修,2025,(05):71-73.
- [26]王军敏,林辉.基于轻量化模型和迁移学习的花卉识别[J].平顶山学院学报,2023,38(05):43-47.
- [27]齐振岭.基于深度学习的牡丹花卉识别与部署的研究及实现[D].聊城大学,2023.DOI:10.27214/d.cnki.glcsu.2023.000625.
- [28]赵友山.基于ResNet神经网络的花卉图像分类研究[J].电脑知识与技术,2024,20(32):23-25.DOI:10.14004/j.cnki.ckt.2024.1644.
- [29]陈杰.基于YOLOv5的花卉种类识别[D].长江大学,2024.DOI:10.26981/d.cnki.gjhsc.2024.000485.
- [30]曹越,上官伟,Arnoud Visser,陈俊杰,柴琳果 & 蔡伯根.基于模式匹配注意力机制的车辆轨迹预测.中国公路学报,1-15.
- [31]李雪芳.融入注意力机制的深度神经网络小目标检测方法[D].山西大学,2023.DOI:10.27284/d.cnki.gsxiu.2023.000292.

致 谢

时光荏苒，大学四年转瞬即逝，转眼间我的毕业论文也接近尾声，在这段充满挑战的旅程中我感到收获颇丰，其中有老师的指导、舍友的帮助和家人的支持，在此我特别想向他们致以最真挚的感谢。

首先衷心感谢我的指导老师范庆辉老师，老师在课题选题、研究方法、系统设计以及论文撰写过程中给予了我悉心的指导和帮助，无论是在技术难题的攻克上还是论文写作的规范性方面，都给了我很大的启发和支持，使我在学术道路上不断成长和进步，让我受益终身，在此向范庆辉老师致以最诚挚的祝福和感谢，祝老师身体健康，万事如意，桃李三千。

同时非常感谢舍友们在我学习和研究过程中提供的鼓励和帮助，祝他们学业有成，万事如意。

最后感谢我的父母在我学业上的支持，谢谢他们在背后默默的支持和帮助，谢谢他们一路上的包容和关爱，让我不断前行，衷心地祝愿他们身体健康。